Curso de Análise Estatística
Caderno de Atividades

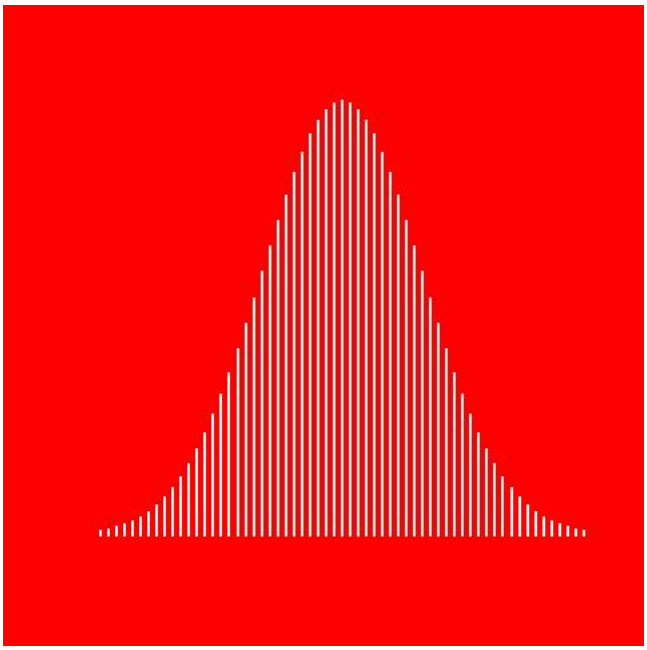

Brasília - DF
maio de 2019

Sumário

Exercício 1 **4**

Exercício 2 **5**

Exercício 3 **7**

Exercício 4 **9**

R conceitos básicos **11**

R operações básicas **13**

Desvio Condicionais e Laçõs de Repetição **22**

Listas **25**

Exercício 1

Questão 1 O arquivo `GRAVIDEZ.csv` traz somente a variável `duracao`, que é a duração em dias da gestação de uma criança observada em um conjunto de mulheres.

i - Use a função `read.csv` para gerar o dada frame dados.

ii - Use a função `str( )` e indique o número de observações.

iii - Classifique a variável `Duracao` em quantitativa (discreta/contínua) ou qualitativa (nominal/ordinal).

iv - Obtenha os valores das seguintes estatísticas para a variável `Duracao`: valor mínimo, valor máximo, 1º quartil, mediana, 3º quartil e a média das variáveis quantitativas.

v - Faça uma tabela de frequência para a variável `duracao`.

vi - Obtenha as seguintes estatísticas de dispersão para a variável `Duracao`: variância, desvio padrão, amplitude e coeficiente de variação.

vii - Faça o histograma e o boxplot para a variável `Duracao`.

Exercício 2

Atividade 1 - O Arquivo `Galton.xlsx` tem um pasta chamda Galton com as seguintes colunas:

i - família - identifica a família pesquisada.

ii - pai - altura do pai em polegadas.

iii - mãe - altura da mae em polegadas.

iv - sexo - sexo do filho (M - Masculino, F - Feminino).

v - altura - altura do filho.

vi - filhos - quantidade de filhos na família pesquisada.

Com o objetivo de verificar se há diferença entre as alturas dos meninos e meninas, faça o que segue:

i - Torne disponível para uso os recursos do pacote xlsx (`library`).

ii - Com a função `read.xlsx()`, crie o data frame `ALTURA`, com as variáveis sexo e altura. Dica: use os argumentos: `sheetName = "Galton"` e `colIndex = c(4,5)`.

iii - Obtenha as seguintes estatísticas descritivas para a variável `altura`: média, máximo, mínimo, 1º quartil, mediana, 3º quartil e desvio padrão.

iv - Com base no valor máximo e no valor mínimo, é razoável propor que a altura seja agrupada em classes que vão de 56 a 80 com amplitude intervalar de 2.Assim, com a função `seq()`, crie o vetor `limites` com valores que iniciam e 56 e terminam em 80 de 2 em 2.

v - Crie um histograma para a variável altura com as seguintes especificações:

- a - Título do gráfico (`main=`): "Alturas observadas".
- b - Suprima o título do eixo dos y (`ylab=`).
- c - Título do eixo dos x (`xlab=`): "Altura (polegadas)".
- d - Suprima a apresentação dos eixos x e y (`axes=F`).
- e - O limites do eixo x são 56 e 80.: `xlim=c(56,80)`.
- f - Defina como limite das classes do histograma os valores do vetor `limites` (`breaks=limites`).
- g - A cor deve ser tomato4.
- h - Execute o comando `axis(1,at=limites)`. Qual o seu efeito no gráfico?

vi - Execute os seguintes comandos para criar as cores cor_menino e cor_menina. Os argumentos são valores entre 0 e 1 e indicam o percentual de cor vermelha, verde, azul e o nivel de trasparência.

```
cor_menino <- rgb(red = 0.87, green = 0.83, blue = 0.71, alpha=0.5 )
cor_menina <- rgb(red = 0.70, green = 0.77, blue = 0.30, alpha=0.5)
```

vii - Faça um boxplot para a variável altura com as seguintes especificações:

- a - Título do gráfico (`main=`): "Alturas observadas".
- b - Cor: tomato4.
- c - Use o argumento `pch=4`.

viii - Crie o data frame **menino** com as observações com o valor da variável sexo igual a M. Dica: `menino <- ALTURA[ALTURA$sexo=="M", ]`

ix - Crie o data frame **menina** com as observações com o valor da variável sexo igual a F.

x - Crie um histograma para a variável altura do data freme **menino** com as seguites especificações:

- a - Título do gráfico (`main=`): "Alturas observadas por Sexo.".
- b - Suprima o título do eixo dos y (`ylab=' '`).
- c - Título do eixo dos x (`xlab=`): "Altura (polegadas)".
- d - Suprima a apresentação dos eixos x e y (`axes=F`).
- e - O limites do eixo x são 56 e 80.: `xlim=c(56,80)`.
- f - Defina como limite das classes do histogram os valores do vetor `limites` (`breaks=limites`).
- g - A cor deve ser `cor_menino`.
- h - Execute o comando `axis(1,at=limites)`. Qual o seu efeito no gráfico?

xi - Crie um histograma para a variável altura do data freme **menina** com as seguites especificações:

- a - Suprima o título do gráfico (`main=' '`).
- b - Suprima o título do eixo dos y (`ylab=' '`).
- c - Suprima o título do eixo dos x (`xlab=' '`).
- d - Suprima a apresentação dos eixos x e y (`axes=F`).
- e - O limites do eixo x são 56 e 80: `xlim=c(56,80)`
- f - Defina como limite das classes do histograma os valores do vetor `limites` (`breaks=limites`).
- g - A cor deve ser `cor_menina`.
- h - Execute o comando `axis(1,at=limites)`. Qual o seu efeito no gráfico?
- i - Use o argumento `add=T`, para que esse histograma seja plotado no histograma dos meninos.
- j - Execute o comando abaixo. Qaul o seu efeito no gráfico?

```
legend("topright", c("meninos","meninas"),
       fill=c(cor_menino,cor_menina),bty="n")
```

xii - Responda: Há diferença entre a altura dos meninos e das meninas?

Exercício 3

Questão 1 - O arquivo **Auto.csv** armazena informações sobre 392 veículos. As variáveis observadas são:

- `mpg` : Milhas por galão.
- `cylinders` : Número de cilindros entre 4 e 8.
- `displacement` : Deslocamento volumétrico do motor (polegadas cúbicas).
- `horsepower` : Potência do motor.
- `weight` : Peso do veículo (libras).
- `acceleration` : Tempo, em segundos, para acelerar de 0 a 60 mph.
- `year` : Ano do modelo.
- `origin` : Origem do veículo:1. Americano, 2. Europeu, 3. Japonês.
- `name` : Nome do veículo.

Execute o solicitado.

(a) Classifique as varáveis em quantitativas(1) ou qualitativas (2).

a) `mpg` ( )	b) `cylinders` ( )	c) `displacement` ( )
d) `horsepower` ( )	e) `weight` ( )	f) `acceleration` ( )
g) `year` ( )	h) `origin` ( )	i) `name` ( )

(b) Qual o "ranger", amplitude total, da variável `mpg`?

(c) Qual a moda da variável `cylinders`?

(d) Qual a origem mais comum dos veículos analisados?

(e) Compare os coeficientes de varição das variáveis `weight` e `acceleration`?

(f) Crie um data frame que tenha somente veículos americanos e sem a coluna `origin`, isto é, a 8ª coluna.

(g) Execute o comando `round(cor(auto[,c(1,2,3,4,5,6)]),2)`. O que ele faz? Faça dois gráficos de dispersão: um entre as variáveis mais correlacionadas `positivamente` e outro para as mais correlacionadas `negativamente`.

(h) Execute o comando `tapply(auto$weight,auto$origin, mean)`. Obtenha o `mpg` médio por `cylinders`.

Questão 2 - Execute e interprete o programa R abaixo:

```
# runif(1) - retorna uma amostra de de tamanho de  uma
#            população uniforme de valores entre 0 e 1
# rnorm(x,mena,sd) - retorna  uma amostra de tamanho x
#            de uma população  normal de media  mean e
#            desvio padrão sd.

valor <- NA
for (i in 1:1000)
{
  aux <- runif(1)
  if (aux <= 0.30)
   {
        valor[i]<- rnorm(1, mean=5,sd=2)
    }
  else
    {
       valor[i]<- rnorm(1,mean=15,sd=2)
     }
}

hist(valor)
```

Questão 3 - Execute e interprete o programa R abaixo:

```
moeda <- c(1,2,1,1,1,2,2)
valor <- c(500,250,300,400,600,100,350)

compras <- data.frame(moeda,valor)
compras$reais <- ifelse(compras$moeda ==1 ,
                        compras$valor * 0.8,
                        compras$valor * 0.5)
```

Questão 4 - O arquivo `ENTORPECENTES.xlsx` possui duas planilhas: `maconha` e `cocaina`. Crie os data frames `maconha` e `cocaina`, de forma que, os dois possuam a variável `unidade`. Use a função `merge()` par gerar o data frame `droga` que unifica as informações de maconha e cocaína da mesma unidade. Use a função `write.xlsx()` para criar o arquivo `DROGAS.xlsx` Dicas: `?merge` e argumento `all=T`.

Exercício 4

Questão 1 - O arquivo **Orcamento.xlsx** armazena informações orçamentárias dos anos de 2016 e 2017 da Policia Federal. Os nomes das colunas desse arquivo são:

- `Ano Lançamento`
- `Grupo Despesa`
- `UG Executora`
- `UGE - UF`
- `DESPESAS EMPENHADAS`
- `DESPESAS LIQUIDADAS`
- `DESPESAS INSCRITAS EM RP NAO PROCESSADOS`

Execute o solicitado.

(a) Deixe pronta para uso as bibliotecas `xlsx` e `sqldf`.

(b) Crie o data frame `orcamento` com os dados da planilha Orcamento.xlsx.

(c) Qual o efeito do comando abaixo no data frame `orcamento`?

```
names(orcamento) <- c("ANO", "GD","UG","UF",
                      "EMPENHADO","LIQUIDADO","RP")
```

(d) Classifique as varáveis em quantitativas(1) ou qualitativas (2).

a) `ANO` ( ) b) `GD` ( ) c) `UG` ( )

d) `UF` ( ) e) `EMPENHADO` ( ) f) `LIQUIDADO` ( )

g) `RP` ( )

(e) Acrescente ao data frame `orcamento` a variável quantitativa `EXECUTADO`, que é a soma de `LIQUIDADO` com `RP`.

(f) Obtenha as frequências das variáveis qualitativas.

(g) Crie a função `est` que retorne a média, os quartis e o desvio padrão de uma variável quantitativas.

(h) Os valores observados nas estatísticas são coerentes?

(i) Qual variável apresenta maior coeficiente de variação?

(j) Crie, usado o operador `[,]`, o data frame `Ano2016` com as informações orçamentárias do ano de 2016.

(k) Crie, usando `SQL`, o data frame `Ano2017` com as informações orçamentárias do ano de 2017.

(l) Qual o valor total empenhado, liquidado, RP e executado da PF por ano? Use um `select` para responder.

(m) Qual a UG com maior execução por ano? Por quê?

(n) Verifique se o valor empenhado está relacionado com a execução.

(o) Na PF, como está a execução por grupo de Despesa? E por UG?

`Questão 2 -` Execute e interprete o programa R abaixo:

```
x<- "select ANO, SUM(EMPENHADo) as empenhado ,
                SUM(EXECUTADO) as executado
from orcamento
group by ANO"

dados<-sqldf(x)
row.names(dados) <- dados[,1]
dados <- dados[,-1]

barplot(t(as.matrix(dados)),
beside = T , ylim = c(0, 8e+10),
col = c("bisque", "navy"), border= c("bisque", "navy"),
legend.text=c("Empenhado","Executado"),
args.legend=c(x="top", bty = "n", horiz=T)
)
```

1. Qual o objetivo da função `row.names( )`?
2. Qual o objetivo da função `t( )`?
3. Qual o objetivo da função `as.matrix( )`?

R conceitos básicos

Questão 1 - Qual a função que encerra o R?

a) `Quit( )` b) `quit( )` c) `Exit( )` d) `exit( )`

Questão 2 - Qual a função que apresenta o caminho da pasta usada como "working directory"?

a) `ls( )` b) `rm( )` c) `setwd( )` d) `getwd( )`

Questão 3 - Qual a função que define a pasta a ser usada como "working directory"?

a) `par( )` b) `q( )` c) `setwd( )` d) `getwd( )`

Questão 4 - Qual a expressão que armazena no vetor `y` a média do vetor `x` ?

a) `y <- sum(x)/length(x)` b) `y <- sum(x)**2/(length(x)-1)`

c) `y <- length(x)/sum(x)` d) `y <- (length(x)-1)/sum(x)`

Questão 5 - Por meio do R foram criados os vetores `x`, `y` e `z`. Qual a expressão que **não** apaga esses vetores ?

a) `ls(list=rm())` b) `rm("x","y","z")`

c) `rm(list=ls())` d) `rm(list=letters[24:26])`

Questão 6 - Qual a função que retorna o número de elementos de um vetor `x`?

a) `dim(x)` b) `nrow(x)` c) `ncol(x)` d) `length(x)`

Questão 7 - Em relação a um *vetor*, qual informação é incorreta?

a) Todos os seus elementos são do mesmo tipo.

b) Cada elemento ocupa uma posição específica.

c) Pode ser criado pela função `vector()`.

d) A função `ncol( )` retorna o seu número de elementos.

Questão 8 - Em relação a um *data frame*, qual informação é incorreta?

a) É organizado em linhas (observações) e colunas (variáveis).

b) As variáveis podem ser de tipos diferentes.

c) As variáveis devem ter o mesmo número de elementos.

d) A função `length( )` retorna o seu número de linhas.

Questão 9 - Qual expressão está incorreta?

a) `x <- y <- 1` b) `1 -> x -> y` c) `x = y = 1` d) `1 = x = y`

Questão 10 - Considere o sistema operacional Windowns, qual o comando define a pastas **E:\X** como a "working directory"?

a) `setwd("E:\X")` b) `setwd("E:/X")` c) `getwd("E:/X")` d) `getwd("E:\\X")`

Questão 11 - Sejam os vetores `x <- 1` e `y <- c(2,3)`. É correto afirmar, sobre `z = x + y`:

a) `z` tem 1 elemento com valor igual a 3.

b) `z` tem 2 elementos, cujos valores são 3.

c) `z` tem 2 elementos, e equivale ao vetor `c(3,4)`.

d) `z` não existe, pois `x` e `y` têm números de elementos diferentes.

Questão 12 - Sejam o vetor `x <- c(1,2)`. O valor de `z = 3*5 + x` é igual a

a) `c(16,2)` b) `c(1,17)` c) `c(16,17)` d) `c(15,30)`

Questão 13 - Dado `x <- c(2,4,NA)`, qual o resultado de `mean(x)`?

a) `3` b) `2` c) `NA` d) `8`

Questão 14 - Com `x <- c(3,4,5,NA)`, qual o resultado de `sum(x,na.rm=T)/length(x)`?

a) `3` b) `NA` c) `4` d) `12`

Questão 15 - Dado `x <- matrix(c(1,2,3,4), byrow=F, nrow = 2)`. É correto afirmar que

a) $x = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$ b) $x = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ c) `x[1,1]+x[1,2]=3` d) `sum(x[,1])=4`

Questão 16 - Como selecionar os elementos da segunda coluna de uma matriz X_{3x4}?

a) `X[,2]` b) `X[2,]` c) `X[2]` d) `x[,-2]`

Questão 17 - Em relação a uma *matrix*, qual informação é incorreta?

a) É organizada em linhas e colunas.

b) Os seus elementos podem ser de tipos diferentes.

c) A função `ncol( )` retorna o número de colunas da matriz.

d) A função `length( )` retorna o número de elementos da matriz.

Questão 18 - Seja o vetor `x <- c(1,2,3)`, qual a opção que retorna o número de elementos do vetor `x`?

a) `nrow()`

b) `ncol()`

c) `dim()`

d) `length()`

R operações básicas

Início

O R pode ser operado em modo interativo. Assim, todo comando digitado após o `>` (prompt) é executado quando a tecla **ENTER** é pressionada, e os resultados são apresentados nas linhas seguintes.

```
> 5 + 2
[1] 7
> 1:5
[1] 1 2 3 4 5
> seq(1,5,by=1.5)
[1] 1.0 2.5 4.0
```

Detalhes importantes: O interpretador R diferencia uma letra maiúscula de uma minúscula. Logo, o termo 'AB' é diferente de 'Ab', 'aB' e 'ab'. O interpretador pode receber vários comandos por linha, desde que sejam separados por ';' (ponto-e-vírgula). Caso pressione **ENTER** no meio de um comando, será apresentado o simbolo '+' no lugar do '>' permitindo que se prossiga o comando. Toda linha iniciada por '#' (jogo-da-velha) é considerada como comentário e não é executada.

```
> # Atribuindo um conjunto de valores a x
> x <- c(1,3,4,4,9,9,
+        7,6,5,6,2,1)
> # Calculando a média dos valores em x
> mean(x)
[1] 4.75
```

Questão 1 - Corrija e execute o código abaixo:

```
Calcula a soma de x + y
x <- 3 y <- 5
#soma de x + y
X + y
```

Questão 2 - Corrija e execute o código abaixo:

```
# x <- c(2,3,4) vetor quantidade
y <- C(5,2,1) # vetor preco
# o vetor custo é dado por
custo = X * y
```

Questão 3 - Qual o efeito da função `getwd( )`?

Questão 4 - Crie no R os objetos `diretorio <- getwd()` e `a = 2`. Qual o efeito da execução da função `ls( )` e da expressão `rm(list=ls())`?

Questão 5 - Qual o efeito da função `setwd("C:/")`?

Pacotes [1]

O programa R é composto de 3 partes básicas:

1. O R-base, o "coração" do R, que contém as funções principais disponíveis quando iniciamos o programa,
2. Os pacotes recomendados (*recommended packages*), que são instalados junto com o R-base, mas não são carregados quando iniciamos o programa. Por exemplo, os pacotes `MASS`, `lattice`, `nlme` são pacotes recomendados – e há vários outros. Para usar as funções destes pacotes, deve-se carregá-los antes com o comando `library()`. Por exemplo, o comando `library(MASS)` carrega o pacote `MASS`.
3. Os pacotes contribuídos (*contributed packages*), que não são instalados junto com o R-base. Estes pacotes, disponíveis na página do R são pacotes oficiais. Estes pacotes adicionais fornecem funcionalidades específicas, e para serem utilizados devem ser copiados, instalados e carregados, conforme explicado abaixo. Para ver a lista deste pacotes com uma descrição de cada um deles acesse a página do R e siga os links para CRAN e Package Sources.

Antes de instalar o pacote, você pode ver se ele já está instalado/disponível. Para isto inicie o R e digite o comando:

```
> require(NOME_DO_PACOTE)
```

Se ele retornar T, é porque o pacote já está instalado/disponível e você não precisa instalar. Se retornar F, siga os passos a seguir.

A instalação e uso dos pacotes vai depender do seu sistema operacional e os privilégios que você tem no seu sistema. Na explicação a seguir assume-se que você está em uma máquina conectada à internet.

Instalação em máquinas com Windows ou IOS: Neste caso, basta usar o comando `install.packages()` com o nome do pacote desejado entre aspas. Por exemplo, para instalar o pacote `CircStats` digite:

```
> install.packages('CircStats')
```

O pacote vai ser instalado no sistema e ficar disponível para todos os usuários. Para usar o pacote basta digitar `library(CircStats)` ou `require(CircStats)`.

Questão 1 - Instale o pacote `googlesheets`.

[1] http://www.leg.ufpr.br/ paulojus/embrapa/Rembrapa/Rembrapase36.html visitado em 24/01/2018

Pedindo Ajuda

O R disponibiliza um rico sistema de ajuda (help). Entretanto, ele é escrito para usuários intermediários ou avançados. Seguem as formas mais comuns de consultar a documentação referente a um tópico.

Função	Help retornado	Exemplo
`help.start( )`	página na web	`help.start( )`
`help(termo)`	relacionado ao termo	`help (summary)`
`?termo`	relacionado ao termo	`?summary`
`?"operador"`	relacionado ao operador	`?":"`
`help.search("string")`	páginas com a string	`help.search("car")`
`??"string"`	páginas com a string	`??"car"`
`example(termo)`	executa exemplos	`example(summary)`
`help(dataframe)`	decreve data frame	`help(esoph)`

Questão 1 - Consulte o help da função `sum( )`. Quais seções são apresentadas?

Questão 2 - Leia o help do data frame `cars`.

Questão 3 - Consulte a seção 'Values' retornada pela função `help( )` aplicada aos operadores `%%`, `%/%` e `:` (dois pontos).

Questão 4 - Leia o help para `seq` e execute os códigos R da seção 'Example'.

Questão 5 - Pesquise o help a função `demo( )` e a aplique no pacote *graphics*.

Geradores de Sequências

O operador `:` gera uma sequência regular. A forma de uso é `a:b`, `a` é o valor inicial e `b` é o valor final. Para maiores detalhes `?seq`.

```
> 1:4
[1] 1 2 3 4
> 4:1
[1] 4 3 2 1
```

Questão 1 - Use o operador **:** para gerar as sequências:

a) de -1 a -4

b) de -4 a -1

Questão 2 - Use o operador **:** para gerar as sequências:

a) de 3.1514 a 6

b) de 6 a 3.1514

A função `seq()` gera também uma sequência de valores, mas permite um maior controle do usuário. Detalhes: `?seq`. Uma forma de uso é `seq( a , b , by= c)`, onde `a` é o valor inicial, `b` é o valor final e `c` o incremento.

```
> seq(1, 9, by = 2)
[1] 1 3 5 7 9
> seq(1, 9, by = pi)    # encerra antes de b
[1] 1.000000 4.141593 7.283185
> seq(1, 4, by = 0.5)
[1] 1.0 1.5 2.0 2.5 3.0 3.5 4.0
```

Questão 3 - Gere um sequência com 10 elementos, que inicia em 1 e termina em 2 com a função `seq( )`. Consulte no help o argumento `length.out=`.

Questão 4 - Execute o código abaixo. Consulte o help e mude o tipo de linha , troque a cor para azul e altere o incremento de x para 0.01

```
> x <- seq(-1,1,by=0.05)
> y <- x^2
> plot (x,y,type="b", col="red")
```

Questão 5 - Desenvolva um código que: defina um vetor com valores de -1 a 1, com incremento de 0.05, e um outro vetor y que receba os valores de x elevado ao cubo, por fim, faça um gráfico de dispersão para os dados x e y, com a cor dos pontos em verde.

R como Calculadora

O R pode operar com valores constantes numéricos e ser utilizado como uma calculadora. Os operadores aritméticos são: **+ (soma)**, **- (subtração)**, **/ (divisão)**, *** (produto)**, **^ (potência)**, **%% (resto da divisão)** e **%/% (quociente).**

Questão 1 - Efetue no R

a) 5×3 b) 5%%3 c) 5%/%3

O resultado de uma expressão aritmética pode ser armazenado em vetor por meio dos operadores **<- (menor,hífen)** ou **= (igual)**. Exemplo: `a <- 1 + 2`.

Questão 2 - Dado o comando `a <- 5 * 4 + 3 ^ 3` . Assinale o valor atribuído ao objeto `a`.

a) 47 b) 54 c) 29 d) 50

Vetor é um objeto capaz de armazenar vários valores em uma determinada ordem. A forma mais usual de se criar um vetor é por meio da função `c( )`. Exemplo: `c(5,6,7)`.

Questão 3 - Assinale a opção correspondente ao código que atribui ao vetor `a` os valores 5, 8, 9 e 1, nessa ordem.

a) `a <- c(1,5,8,9)` b) `a <- c(5,8,9,1)` c) `A <- c(5,8,9,1)`

Operações aritméticas com vetores, com o mesmo número de elementos, são realizadas elemento a elemento. O resultado é um vetor com o mesmo `tamanho (length)` dos vetores iniciais.

```
> x1 <- c(2,3); x2 <- c(1,2); x3 <- x1+x2
> x3
[ 1 ] 3 5
```

Questão 4 - Escreva um código que gere vetores x1 e x2 com 4 elementos aleatórios. E crie um terceiro vetor que contenha o produto de x1 e x2.

Expressões aritméticas que envolvem **vetores com diferentes números de elementos** têm como resultado um **vetor** com o número de elementos igual ao do vetor com o **maior** número de elementos. Os demais vetores têm seus elementos repetidos até alcançarem o mesmo número de elementos do "maior" vetor.

```
 x1 <- c(2,3,4,5,6,7); x2 <- c(7,8); x3 <- x1+x2; x3
[1]  9 11 11 13 13 15
>
```

Caso haja, na expressão algum vetor cujo número de elementos não seja divisor do vetor com maior número de elementos serão emitidos alertas, mas a expressão será efetuada.

```
> x1 <- c(2,3,4,5,6); x2 <- c(7,8); x3 <- x1+x2; x3
Warning message:
In x1 + x2 :
  longer object length is not a multiple of shorter object length
[1]  9 11 11 13 13
```

Questão 5 - Escreva um código que gere vetores x1 e x2, com 4 e 2 elementos quaisquer, respectivamente. Após, defina um terceiro vetor com a soma de x1 e o dobro de x2.

Questão 6 - Dado que `qtd <- c (2,4,5)` e `preco<- c(19.5, 15, 20)`, escreva um código para gerar o vetor `custo`, que é definido como o produto entre `qtd` e `preco`.

Questão 7 - O volume de uma esfera de raio r é dado por $\frac{4}{3}\pi r^3$. Use o R para saber qual o volume de uma esfera de raio 5.

.

Questão 8 - O vetor `elsius <- 1:100` armazena um conjunto de temperaturas na escala Celsius. Converta as temperaturas armazenadas no vetor *celsius* para escala Fahrenhet. A mudança de escala solicitada é dada pela relação $TF = \frac{9}{5}TC+32$, onde TC é a temperatura em Celsius e TF é a temperatura em Fahrenheit.

O R disponibiliza muitas funções que são úteis para analisar os dados de um vetor. Os comandos `help ( )` ou ? retornam a descrição completa de qualquer função do R. A tabela abaixo apresenta algumas funções.

Função	Valor retornado
`length ( )`	quantidade de elementos
`min ( )`	menor elemento.
`max ( )`	maior elemento.
`sum ( )`	soma dos elementos.
`mean ( )`	média dos elementos.
`median ( )`	mediana dos elementos.
`var ( )`	variância dos elementos.
`sd ( )`	desvio padrão dos elementos.

Questão 9 - Sejam os seguintes dados: { 10, 11, 30, 76, 89, 22 }. Desenvolva um código R que execute

1. Crie um vetor `x` com os dados apresentados.
2. Crie um vetor `x_escala` com os dados ajustados para um escala de 0 (zero) a 10 (dez). Dica:

$$x\_escala = \frac{x - \texttt{valor mínimo}}{\texttt{valor máximo - valor mínimo}} \times 10$$

Questão 10 - O código `x <- rnorm(100)` cria uma amostra de uma populção normal. Desenvolva um código R que execute

1. Crie o vetor `n`, que armazene o número de elementos em `x`.
2. Crie o vetor S, que armazene o total dos elementos em `x`.
3. Crie o vetor x_medio que armazene a soma dos valores em `x` dividido pelo o número de valores em x. Compare o valor de `x_medio` com o de `mean(x)`.

Questão 11 - O código `x <- rnorm(500,mean=5,sd=2)` retira uma amostra de tamanho 500 de uma população normal com média 5 e variância 4. Desenvolva um código R para

1. Usar as funções `mean( )` e `var( )` para verificar se a média e a variância da amostra em `x` têm valores próximos aos valores populacionais.
2. Criar o vetor `x_padrao` dado por

$$x\_padrao = \frac{\texttt{x - media de x}}{\texttt{raiz quadrada da variância de x}}$$

3. Calcular a média e a variância de `x_padrao`.
4. Gerar uma nova amostra x com média = 10 e variância 4 (`x<-rnorm(500,10,2)`). Refaça os itens 1., 2. e 3. O que se observa com a média e a variância dos valores de `x_padrao`?

Dados no R

O R opera sobre estruturas de dados, que incluem os **vetores**, **fatores**, **matrizes**, **arrays**, **listas** e **data frames**.

O vetor é uma estrutura que comporta um conjunto ordenado de dados. O vetor `x`, que consiste dos números 10.4,05.6, 3.1, 6.4 e 21.7, pode ser gerado pelo código:

```
x <- c(10.4, 5.6, 3.1, 6.4, 21.7)
```

Os valores que constituem os vetores são clamados de elementos. Em função do tipo de elemento que comporta, um vetor é um dos seis tipos básicos: logical, integer, real, complex, caracter (string) and raw (bruto). Exemplos:

```
> # Vetor logico
> x <- c(TRUE, FALSE, T, F, 5> 4)
> # Vetor Interiro
> y <- c(1L, 2L)
> # Vetor Real
> z <- c(1, 2)
> # Vetor Complexo
> w <- c(1+2i, 1+0i, 1i)
> # vetor caracter
> k <- c("casa", 'apartamento')
> # Vetor raw armazena seus valores em formato hexadecimal
> y <- charToRaw( "oi tudo bem")
> y
 [1] 6f 69 20 74 75 64 6f 20 62 65 6d
```

Todos os elementos de um vetor são ou numéricos (integer, real, complex, raw), ou lógicos ou caracter. Caso se tente gerar um vetor com valores numéricos, ou lógicos, e com valores caracter, os valores numéricos são convertidos para caracter.

Questão 1 - Execute um código **R** que use a função `c ( )` para gerar o vetor `y` com os valores {"casa", 3.5, $(7 > 2)$}.

Questão 2 - Há erros em x <- c('casa", "ap", 'loja')? Se houver, explique.

Questão 3 - Execute um codigo **R** que gere um vetor com todas as letras minúsculas do alfabeto. Dica: LETTERS.

Fator é uma estrutura útil para armazenar dados ordinais ou nominais. A função `factor( )` converte um vetor em um fator , tem 3 três argumentos:

- `x`- vetor que será convertido em fator.
- `levels` – indicar as categorias ou níveis do fator.
- `labels` – nomeia os níveis.

Exemplo: Cria o fator `area` a partir do vetor numérico `area` para armazenar a informação área de conhecimento.

```
area   <- c(1,1,2,1,2,2,1,1)
area <- factor ( area ,
                 levels = c(1,2,3),
                 labels = c("Humanas", "Exatas", "Saude"))
```

Questão 4 - Experimente os seguintes comandos, onde o fator area é o utilizado no texto introdutório.

1 - `mean(area)`

2 - `sum(area)`

3 - `area * 2`

Questão 5 - Crie um fator que contenha os temos: ”abacaxi”, ”maçã”, ”kiwi”e ”uva”.

Acesso a valores

Data Frame é uma estrutura de dados retangular, na qual as colunas são as variáveis e as linhas são as observações. A forma mais comum de criar um data frame é por meio da leitura de dados armazenados em outros arquivos, como txt ou xlsx.

A função `data.frame( )` cria um data frame a partir de vetores ou fatores.

```
idade <- c(18, 17, 19, 21, 22, 25, 18, NA)
area   <- c(1,1,2,1,2,2,1,1)
genero <- c("f","m","f","f","m","f","m","f")

area <- factor ( area ,
                 levels = c(1,2,3),
                 labels = c("Humanas", "Exatas", "Saude"))

dados <- data.frame ( area, genero, idade)
```

Pode-se extrair uma variável de um data frame digitando o nome do data frame seguido por $ e o pelo nome da variável.

```
dados$area
```

Observações e variáveis de um data frame podem ser extraídos com o operador [linha, coluna].

- **dados [x , y]** – elemento na x^{a} linha e y^{o} coluna.
- **dados [, y]** – todas as linhas da y^{a} coluna.
- **dados [x ,]** – todas as colunas da x^{a} linha.
- **dados [n]** – retorna um data frame formado pela coluna n.

Questão 1 - Digite os comandos que geraram o data frame `dados` do texto introdutório. Calcule a média da variável `area` e da variável `idade`.

Questão 2 - Execute os comandos `help(mtcars)`, `str(mtcars)` e `head(mtcars)`. Descreva os resultados obtidos.

Desvio condicionais e laços de repetição

Desvio Condicional

O comando `if(condição)` permite que um conjunto de comandos (bloco) seja executado se condição for TRUE.

```
Sintaxe:
if ( condição )
{
bloco
}
```

```
Exemplo:
x <- 4
if ( x > 0 ) {
print("Número Positivo")
}
```

O comando `if (condição) {bloco 1} else {bloco 2}` permite definir um bloco a ser executado quando condição for FALSE.

```
Sintaxe:
if ( condição )
{
bloco 1
} else {
bloco 2
}
```

```
Exemplo:
x <- 4
if ( x > 0 ) {
print("Número Positivo")
} else {
print("Número Negativo")
}
```

O comando `if (condição) {bloco 1} else {bloco 2}` admite um outro comando `if (condiçao k) {bloco x} else {bloco y}`.

```
Sintaxe:
if (condição  1){
bloco 1
} else  if (condição 2) {
    bloco 2
} else  if (condição 3) {
bloco 3
} else {
  bloco 4
}
```

```
Exemplo:
x <- 4
if ( x > 0 ) {
print("Número Positivo")
} else if ( x < 0 ) {
print("Número Negativo")
} else {
print("Zero")
}
```

Importante: A condição a ser analisada pode envolver vetores numéricos ou lógicos, mas somente o primeiro elemento do vetor é considerado. Ao ser usado vetores numéricos o valor zero é considerado FALSE e os demais TRUE. Note que o `else` sempre vem na mesma linha do } que encerra o bloco de comandos anterior.

Questão 1 - Escrava um programa R que apresente na tela se o valor armazenado em `x` é **par** ou **ímpar**. O valor será **par**, se e somente se, ocorrer `x %% 2 = 0`, caso contrário, o número será classificado como **ímpar**. Dica: O operador `%%` retorna o resto de uma divisão.

A função `ifelse()` tem comportamento semelhante a `if (condição) {bloco 1} else { bloco 2}`, porém a condição é verificada em todos os elementos de um vetor.

```
                          a = c(5,7,2,9)
ifelse(condição,x,y)      ifelse(a %% 2 == 0,"par","ímpar")
                          [1] "ímpar"  "ímpar"  "par" "ímpar"
```

O vetor resposta recebe o elemento `x` se a condição for verdadeira e `y` se a condição for falsa. De outra maneira, o elemento `i` do resultado ira ser o elemento `x[i]` se a condição verificada for TRUE, caso contrário o resultado recebe o valor `y[i]`.

Questão 2 - O saldo dos clientes do Banco BSEI estão armazenados no vetor `saldo`. O gerente (você) solicita ao setor de tecnologia a segmentação dos clientes ou na categoria **elite**, saldo superior R$ 5.000,00, ou na categoria **executivo**, para os demais valores de saldos. Em 15 minutos, a tecnologia lhe retorna o vetor `segmento` para a sua homologação. Use a estatística descritiva para homologar o trabalho da tecnologia. Caso o vetor `segmento` não seja homologado , escreva um código R que gere a segmentação correta.

Importante: Os vetores `saldo` e `segmento` estão armazenados no arquivo BSEI.RData.
Dicas: `load( ), setwd(), ifelse(), tapply(), mean(), min(), max()` e `boxplot()`.

Questão 3 - O data frame `feijao` em sua variável `m` registra a massa, em gramas, de n grãos de um cultivar de feijão. Então,

1. Determine a quantidade de elementos da variável `m`.
2. Faça um histograma e um boxplot para esses dados.
3. Obtenha a média, desvio padrão, o coeficiente de variação e dos descis 10, 50, 70, 90.
4. Classifique os grãos em "A" se a sua massa for maior ou igual a 95% dos outros grãos e em "B" os demais.

Importante: Os dados do data frame `feijão` está no arquivo feijao.csv
Dicas: `read.csv2(), setwd(), ifelse(), hist(), mean(), sd(), max(), quantile(), length()` e `boxplot()`.

Laços de Repetição

O comando `for()` repete um bloco de comandos até que certa variável assuma todos os valores de uma sequencia.

```
Sintaxe:
for ( val in vet )
{
 bloco
}
```

```
Exemplo:
# conta pares
x <- c(2,5,3,9,8,11,6)
t <- 0
for (val in x) {
  if(val %% 2 == 0) t = t + 1
}
print(t)
```

A `vet` é um vetor, que pode ser resultado de uma função como a `seq()`, `c()` ou pelo operador `:`.

No exemplo, conta-se a quantidade de elementos do vetor `x` que é um numero **par**. O comando `for()` faz a variável `val` assumir todos os valores de `x`, um por vez, e caso o valor em `val` seja **par** a variável `t` é incrementada em 1.

Questão 1 - Crie o vetor `x` com 5 elementos escolhidos aleatóriamente do intervalo de 1 até 100, use da função `sample()`. Dessa amostra, apresente os elementos de `x` e a quantidade de números `ímpares` que contém.

O comando `while()` repete um bloco de comandos até certa condição assuma valor FALSE. Em outras palavras o bloco é repetido enquanto a condição for TRUE.

```
Sintaxe:
while (condicao) {
  bloco
 }
```

```
Exemplo:
x <- 1
while (x < 6) {
  print(x)
  x <- x + 1
}
```

Observe que o valor de `x` foi inicializado com um valor que garanta ao menos uma execução do bloco. Note, também, que deve haver a certeza que `condicao` assuma o valor FALSE, em algum momento.

Questão 1 - O fatotial de numero natural $n \leq 1$ é o produto de todos os naturais de 1 a n. O fatorial de 4 é $1 \times 2 \times 3 \times 4 = 24$. Siga os passos para calcular o fatorial de 7 usando o comando `while()`.

1. Inicialize a variável `n` com o valor 7.
2. Inicialize a variável `fatorial` com o valor 1.
3. Inicialize a variável `i` com o valor 1.
4. Enquanto $i \leq n$ faça
   i Atribua a `fatorial` o valor `vatorial * i`
   ii Incremente `i`
5. Print o valor de `fatorial`

Listas

Uma lista R é coleção ordenada de objetos, conhecidos como **componentes**. Os componentes não precisam ser do mesmo modo ou tipo. Uma lista pode ser formada pelos seguntes componentes, por exemplo: uma lista, um vetor numérico, um valor lógico, uma matriz, um vetor complexo, uma matriz de caracteres e uma função.

A função `list()` gera uma lista, como no código abaixo.

```
> Lst <- list (nome = "Fred", esposa = "Maria", no.filhos = 3,
               idade.filhos = c (4,7,9)
```

Os componentes de uma lista são numerados, como em um vetor. Assim, `Lst` é o nome de uma lista com quatro componentes, que são individualmente acessados por `Lst [[1]]`, `Lst [[2]]`, `Lst[[3]]` e `Lst[[4]]`. Se, além disso, `Lst [[4]]` é um vetor, então `Lst[[4]][1]` é sua primeira entrada. A função `length(Lst)` retorna o número de componentes (de nível superior) que possui. Os componentes de uma listas também podem ser nomeados e, nesse caso, um componente pode ser referenciado por seu nome, como em `Lst$nome`. Além disso, também é possível usar os nomes dos componentes da lista dentro dos colchetes duplos. Logo `Lst [["nome"]]` é o mesmo que `Lst$ name`.

- `Lst$nome` é o mesmo que `Lst[[1]]` que é a string "Fred",
- `Lst$esposa` é o mesmo que `Lst[[2]]` que é a string "Maria",
- `Lst$idade.filhos[1]` é o mesmo que `Lst [[4]][1]` que é o número 4.

Isso é especialmente útil quando o nome do componente a ser extraído é armazenado em outra variável, como em

```
> x <- "nome"; Lst[[x]]
```

É importante distinguir `Lst[[1]]` de `Lst[1]`. O operador `[[...]]` selecionar um único elemento, enquanto `[...]` é um operador de subscrição geral. Assim, `Lst[[1]]` retornar o primeiro objeto na lista `Lst` e, se for uma lista nomeada, o nome não será incluído. Já, `Lst[1]` retorna uma sub-lista de `Lst`, consistindo apenas da primeira entrada, se a lista for nomeada, os nomes dos componentes são transferidos para a sub-lista.

Os nomes dos componentes podem ser abreviados até o número mínimo de letras necessárias para identificá-los exclusivamente. Assim, o componente `Lst$coeficientes` podem ser especificados minimamente como `Lst$coe` e `Lst$covariância` como `Lst$cov`.

O vetor `names(Lst)` é um vetor com os nome, na verdade,nentes simom de es dos compoplesmente um atributo da lista como qualquer outro e pode ser tratado como tal. Outras estruturas além das listas podem, é claro, receber um atributo de nomes similarmente.

Questão 1 - A função `lm()` é usada em análises de modelos lineares, por exemplo, uma regressão linear simples. Os resultados obtidos são organizados em uma lista. Execute o código R abaixo:

```
help("iris")
data("iris")
fit<- lm(iris$Petal.Length~iris$Petal.Width)
summary.lm(fit)
names(fit)
length(fit)
plot (iris$Petal.Width, iris$Petal.Length , pch=16, col = "skyblue")
points(iris$Petal.Width, fit$fitted.values, pch=16 , col="orange")
```

Responda:

i- Qual é o conteúdo do data frame `iris`?

ii- Quantos são os componentes lista `fit` e quais os seus nomes?

iii- Qual o resultado da função `plot()` e `points()`

iv- Altere os títulos dos eixos x e y para `largura` e `comprimento`, respectivamente. Dica: `?plot`.

v- Calcule a média dos valores em `fit$residuals` e faça um histograma com esses valores, `hist()`.

vi- Qual é a soma dos quadrados dos resíduos.

Questão 2 - A expressão `x <- rnorm(1500)` retorna um vetor com 1500 números aleatórios retirados de uma distribuição normal com média 0 e desvio padrão 1.
Faça:

i- Leitura rápida do help da função `hist()`.

ii- Calcule a média e variância de `x`, verifique se os valores são próximos aos esperados teoricamente.

iii- Armazene na variável `minimo` o menor valor observado arrendondado para o menor inteiro em `x`, e na variável `maximo` o maior valor observado arrendondado para o maior inteiro.

iv- Armazene em `k` a raiz quadrado do número de elementos em `x` arrendondado para menos.

v- Crie o vetor `limites` que contenha k valores equidistantes que iniciam em `minimo` e terminem em `maximo`. Use a função `seq()`

vi- Faça um histograma com os valores de `x` com as seguintes características:

- `breaks=limites`.
- `xlab=‘ ’` , `main=‘ ’`, `ylab=‘ ’` e `axes=F`

vii- Após a função `hist ()` execute o comando `axis(1, at = limites, labels = round(limites,2))`